

# TPSTAT2\_CHEN\_GUANGYUE\_GROUPE\_3

## 1 Echantillon, Théorème Central Limite, Estimation Monte Carlo

### E1.1

pour simuler les echantillons avec les taille defferentes

```
#mean et var
mymean<-function(echant) {
  s <- sum(echant)
  n <- length(echant)-1
  return (s / n)
}

myvar<-function(echant) {
  s <- 0
  n <- length(echant)-1
  m <- mymean(echant)
  for (x in echant) {
    s <- s + (x-m)^2
  }
  return (s / n)
}

#cette fonction c'est pour représenter les histogramme et calcule les moyennes et les variances , et fai
show_echan <-function (n){
  echans<-matrix(rnorm(n*1000,2,6),nrow = n)
  means=vector(length=1000)
  vars=vector(length=1000)
  for (i in 1:1000) {
    means[i]=mymean(echans[,i])
    vars[i]=myvar(echans[,i])
  }
  str<-paste("les moyennes des echantillons",n)
  hist(means,main = str,freq = FALSE)

  cat("\n",n,"la moyenne empirique ",mean(means))


  #apres faire la renormalisation
  myfun=function(x)((x-2)/(2/sqrt(n)))
  means2=sapply(means,myfun)
  #means2=scale(means, center=T,scale=T)

  str<-paste("les moyennes scalaires des echantillons 'U'",n)
  hist(means2,main = str,freq = FALSE)
```

```
}
```

```
show_echan(5)
```


### les moyennes des echantillons 5



```
##
```


```
## 5 la moyenne empirique 2.555711
```

## les moyennes scalaires des echantillons 'U' 5




```
show_echan(30)
```

## les moyennes des echantillons 30




```
##  
## 30 la moyenne empirique 2.103172
```

## les moyennes scalaires des echantillons 'U' 30




```
show_echan(100)
```

## les moyennes des echantillons 100



```
##  
## 100 la moyenne empirique 2.025317
```

## les moyennes scalaires des echantillons 'U' 100



Quel est

la loi de la moyenne empirique?

La moyenne empirique d'un échantillon est la somme de ses éléments divisée par leur nombre. La loi théorique des moyennes est la loi gaussienne de paramètres  $N(1, 2)$ .

Quel est l'influence de la taille de l'échantillon? On remarque que quand  $N$  est plus grand, les moyennes sont plus proches de 2, et la loi moyenne empirique est plus renormalisée, semble suivre une loi  $N(0, 1)$ .

## E1.2

```
show_echan_de_pareto <-function (n){
  a <- 1.0
  alpha <- 2.5
  echans<-matrix(rpareto(n*1000, a, alpha),nrow = n)
  means=vector(length=1000)
  vars=vector(length=1000)
  for (i in 1:1000) {
    means[i]=mymean(echans[,i])
    vars[i]=myvar(echans[,i])
  }
  str<-paste(" des moyennes empiriques pour pareto",n)
  hist(means,main = str,freq = FALSE)
  cat("\nla moyenne empirique ",n,mean(means))

  #apres faire la renormalisation
  myfun=function(x)((x-1)/(2/sqrt(n)))
  means2=sapply(means,myfun)
```

```


str<-paste("les moyennes scalaires des echantillons 'U'",n)
hist(means2,main = str,freq = FALSE)

}

show_echan_de_pareto(5)

```

## des moyennes empiriques pour pareto 5




```

##
## la moyenne empirique 5 2.055211


```

## les moyennes scalaires des echantillons 'U' 5




```
show_echan_de_pareto(30)
```

## des moyennes empiriques pour pareto 30




```
##  
## la moyenne empirique 30 1.714003
```

## les moyennes scalaires des echantillons 'U' 30



```
show_echan_de_pareto(100)
```


## des moyennes empiriques pour pareto 100



```
##  
## la moyenne empirique 100 1.69691
```



## les moyennes scalaires des echantillons 'U' 100



Quel est la

loi theorique de la moyenne empirique?

$$E = (\alpha * a) / (\alpha - 1)$$

$$\text{Var} = ((a^2) * \alpha) / (((\alpha - 1)^2) * (\alpha - 2))$$

La loi théorique des moyennes est la loi gaussienne de paramètres  $N(\text{Esperance}, \text{Variance})$  avec Esp l'espérance de Pa et Var la variance.

Quel est l'influence de la taille de l'échantillon? On remarque que quand N est plus grand, la loi moyenne empirique est plus renormalisée et semble suivre une loi  $N(0, 1)$ .

### E1.3

```
show_echan_de_Poisson <-function (n){
  echans<-matrix(rpois(n*1000,3),nrow = n)
  means=vector(length=1000)
  vars=vector(length=1000)
  for (i in 1:1000) {
    means[i]=mymean(echans[,i])
    vars[i]=myvar(echans[,i])
  }
  str<-paste("les moyennes des echantillons",n)
  hist(means,main = str,freq = FALSE)

  #apres faire la renormalisation
  myfun=function(x)((x-3)/(sqrt(3)/sqrt(n)))
  means2=sapply(means,myfun)
  #means2=scale(means, center=T,scale=T)
  cat("\nla moyenne empirique ",n,mean(means))
}
```


```

str<-paste("les moyennes scalaires des echantillons 'U'",n)
hist(means2,main = str,freq = FALSE)

}
show_echan_de_Poisson(5)

```

## les moyennes des echantillons 5




```

##
## la moyenne empirique 5 3.7815


```

### les moyennes scalaires des echantillons 'U' 5




```
show_echan_de_Poisson(30)
```

### les moyennes des echantillons 30




```
##  
## la moyenne empirique 30 3.103483
```

### les moyennes scalaires des echantillons 'U' 30




```
show_echan_de_Poisson(100)
```

### les moyennes des echantillons 100



```
##  
## la moyenne empirique 100 3.036778
```

## les moyennes scalaires des echantillons 'U' 100



Quel est la loi de la moyenne empirique? La moyenne théorique d'une loi de Poisson ayant pour paramètre lambda est de lambda, et sa variance est aussi lambda.

Quel est l'influence de la taille de l'échantillon? On remarque que quand N est plus grand, la loi moyenne empirique est plus renormalisée et semble suivre une loi  $N(0, 1)$ .

### E1.4

comment N influence la qualité de cette approximation?

La moyenne empirique est une bonne estimation de l'espérance quand N tend vers l'infini.

## 2 Moyenne et Dispersion

### E2.1 Bienaymé Chebychev dans les cas Gaussien et Poisson

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \alpha) \leq \frac{\text{Var}[X]}{\alpha^2}$$

Pour une loi Gaussienne  $N(\mu, \sigma^2)$ , on a :

$$\begin{aligned}\mathbb{E}[X] &= \mu \\ \text{Var}[X] &= \sigma^2\end{aligned}$$

Pour une loi de Poisson :

$$\begin{aligned}\mathbb{E}[X] &= \lambda \\ \text{Var}[X] &= \lambda\end{aligned}$$

## E2.2(a)

$$\mathbb{P}(|X - \mu| \geq \delta) = \mathbb{E}[\mathbb{1}_{\{|X - \mu| \geq \delta\}}] = \mathbb{E}[Z]$$

, ici

$$Z = \mathbb{1}_{\{|X - \mu| \geq \delta\}}$$

## E2.2(b)

```
estimation_norm <-function (n,delta,a,b){
  echans<-rnorm(n*n,a,b)
  myfonc=function(x) {
    if (abs(x-a) >= delta) {
      return (1)
    }
    return (0)
  }
  echans<-sapply(echans,myfonc)
  y=sum(echans)/n/n
  y<-paste("Gauss:",y)
  print(y)
  return(echans)
}
P_gauss<-estimation_norm(1000,delta=1,0,1)
```

```
## [1] "Gauss: 0.316851"
```

```
estimation_poisson <-function (n,delta,b){
  echans<-rpois(n*n,b)
  myfonc=function(x) {
    if (abs(x-b) >= delta) {
      return (1)
    }
    return (0)
  }
  echans<-sapply(echans,myfonc)
  y=sum(echans)/n/n
  y<-paste("POisson:",y)
  print(y)
  return(echans)
}
P_poisson<-estimation_poisson(1000,delta=1,1)
```

```
## [1] "POisson: 0.632224"
```

```
estimation_pareto <-function (n,delta,a,alpha){
  echans<-rpareto(n*n, a, alpha)
  b<-alpha*a/(alpha - 1)
  myfonc=function(x) {
    if (abs(x-b) >= delta) {
      return (1)
    }
    return (0)
  }
}
```

```

    }
    echans<-sapply(echans,myfonc)
    y=sum(echans)/n/n
    y<-paste("pareto:",y)
    print(y)
    return(echans)
}
P_pareto<-estimation_pareto(1000,delta=1,1,2.5)

```

```
## [1] "pareto: 0.086049"
```

Pouvez-vous déterminer la précision de cette estimation?

$$\mathbb{P}[|\bar{Z}_N - \mathbb{E}[Z]| \geq \epsilon] \leq \frac{\mathbb{V}[Z]}{\epsilon \sqrt{N}}$$

#E2.2(c)

```

#pour la precision d'estimation
precision<- function(X, e) {
  return (var(X) / (e * sqrt(1000)));
}
print("la precision de gauss")

```

```
## [1] "la precision de gauss"
```

```
print(precision(P_gauss,0.05))
```

```
## [1] 0.1368992
```

```
print("la precision de poisson")
```

```
## [1] "la precision de poisson"
```

```
print(precision(P_poisson,0.05))
```

```
## [1] 0.1470567
```

```
print("la precision de perato")
```

```
## [1] "la precision de perato"
```

```
print(precision(P_pareto,0.05))
```

```
## [1] 0.04973924
```

## E2.2(d)

Dans l'inégalité de Chernoff pour le cas Gaussien, en remplaçant les termes on a :

$$\mathbb{P}(X \geq \delta) \leq \exp\left(-\frac{\delta^2}{2\sigma^2}\right)$$

$$\mathbb{P}(X \geq \delta) \leq \exp\left(-\frac{\delta^2}{2\sigma^2}\right)$$

```

BorneChernoff_G <-function(delta,V) exp(- delta**2/(2*(V**2)))
cat("Estimation de Monte-Carlo du terme =", mean(P_gauss))

```

```
## Estimation de Monte-Carlo du terme = 0.316851
```

```
cat("\nBorne de Chernoff =", BorneChernoff_G(1,1))
```

```
##
```

```
## Borne de Chernoff = 0.6065307
```

```
cat("\nDifférence =", BorneChernoff_G(1,1)-mean(P_gauss))
```

```
##
```

```
## Différence = 0.2896797
```

Dans l'inégalité de Chernoff pour le cas Poisson, en remplaçant les termes on a :

$$\mathbb{P}(X \geq \delta) \leq \exp \left( -\lambda \left[ \left( 1 + \frac{\delta}{\lambda} \right) \log \left( 1 + \frac{\delta}{\lambda} \right) - \frac{\delta}{\lambda} \right] \right)$$

```
BorneChernoff_P <- function(delta,l) exp(-l*((1 + (delta / l))*log(1 + (delta / l)) - (delta / l)))
cat("Estimation de Monte-Carlo du terme =", mean(P_poisson))
```

```
## Estimation de Monte-Carlo du terme = 0.632224
```

```
cat("\nBorne de Chernoff =", BorneChernoff_P(1,1))
```

```
##
```

```
## Borne de Chernoff = 0.6795705
```

```
cat("\nDifférence =", BorneChernoff_P(1,1) - mean(P_poisson))
```

```
##
```

```
## Différence = 0.04734646
```

La borne donnée par l'inégalité de Chernoff est bien plus précise que celle donnée par l'inégalité de Bienaymé-Tchebychev.

### E3 (a)

```
chernoff_norm <-function (n,a,b){
  #n fois rnorm(n,a,b)
  echans<-matrix(rnorm(n*n,a,b),nrow = n)
  bornes=vector(length=n)
  vars=vector(length=n)
  count=0
  for (i in 1:n) {
    vars[i]=var(echans[,i])
    bornes[i]=BorneChernoff_G(1,sqrt(vars[i]))
  }
  return(mymean(bornes))
}
B_gausee<-chernoff_norm(20,0,1)
cat("\nBorne de Chernoff de gausse N(0,1) 20=",mean(B_gausee))
```

```
##
```

```
## Borne de Chernoff de gausse N(0,1) 20= 0.5790724
```

```
B_gausee<-chernoff_norm(100,0,1)
cat("\nBorne de Chernoff de gausse N(0,1) 100=",mean(B_gausee))
```



```
##
## Borne de Chernoff de gauss N(0,1) 100= 0.6076926
B_gausee<-chernoff_norm(1000,0,1)
cat("\nBorne de Chernoff de gauss N(0,1) 1000=",mean(B_gausee))
```

```
##
## Borne de Chernoff de gauss N(0,1) 1000= 0.606907
```

```
chernoff_poisson <-function (n,b){
  echans<-matrix(rpois(n*n,b),nrow = n)
  bornes=vector(length=n)
  vars=vector(length=n)
  count=0
  for (i in 1:n) {
    vars[i]=var(echans[,i])
    bornes[i]=BorneChernoff_P(1,vars[i])
  }
  return(mymean(bornes))
}
B_poisson<-chernoff_poisson(20,1)
cat("\nBorne de Chernoff de poisson 20 =",mean(B_poisson))
```

```
##
## Borne de Chernoff de poisson 20 = 0.6946389
```

```
B_poisson<-chernoff_poisson(100,1)
cat("\nBorne de Chernoff de poisson 100=",mean(B_poisson))
```

```
##
## Borne de Chernoff de poisson 100= 0.6800147
```

```
B_poisson<-chernoff_poisson(1000,1)
cat("\nBorne de Chernoff de poisson 1000=",mean(B_poisson))
```

```
##
## Borne de Chernoff de poisson 1000= 0.679914
```

(b) en deduire un estimateur de  $\mu$  et  $\lambda$  de  $E4$  # (a)

```
show_echan_de_Cauchy <-function (n){
  c = rcauchy(n,location=0,scale=1)
  return ( mymean(c))
}
y1<-show_echan_de_Cauchy(20)
y2<-show_echan_de_Cauchy(100)
y3<-show_echan_de_Cauchy(1000)
y4<-show_echan_de_Cauchy(10000)

cat("\nla moyenne empirique 20",y1)
```

```
##
## la moyenne empirique 20 -0.3098972
```

```
cat("\nla moyenne empirique 100",y1)
```

```
##
```

```
## la moyenne empirique 100 -0.3098972
cat("\nla moyenne empirique 1000",y1)

##
## la moyenne empirique 1000 -0.3098972
cat("\nla moyenne empirique 10000",y1)

##
## la moyenne empirique 10000 -0.3098972
```

## (b)expliquer ce compotement

Une v.a  $X$  suivant une loi de Cauchy( $\theta$ ) n'admet pas d'espérance:

$f_X(x, \theta) = \frac{1}{\pi} \frac{1}{1+(x-\theta)^2}$ , et quand  $x \rightarrow +\infty$ ,  $xf_X(x, \theta) \sim \frac{1}{x}$ , donc:

$\mathbb{E}[X] = \int_{-\infty}^{+\infty} |xf_X(x, \theta)|dx$  diverge.

Il n'y a pas d'espérance ,donc le théorème central limite ne s'applique pas, donc la moyenne empirique ne converge pas.

Ceci s'explique par le fait que la probabilité d'obtenir une valeur éloigné de la médiane est trop élevé pour que la moyenne converge.

## (c)Quel est la mediane d'une loi de Cauchy

La médiane d'une loi de Cauchy de paramètres

$(a, x_0)$

est

$x_0$

```
mediance<-function(n){
  echans<-matrix(rcauchy(1000*n,0,1),nrow = n)
  mediances<-vector(length=1000)
  for (i in 1:1000) {
    mediances[i]=median(echans[,i], na.rm = FALSE)
  }
  return(mean(mediances))
}
mediance(20)
```

```
## [1] -0.005702269
```

```
mediance(100)
```

```
## [1] 0.001508898
```

```
mediance(1000)
```

```
## [1] 0.0003411733
```